

Python Machine Learning

Entendendo Machine Learning

Guilherme Silveira
gfsilveira@gmail.com

02/08/2026



Roteiro

- 1 – O que é Machine Learning (ML)?
- 2 – Para quem é Machine Learning?
- 3 – Quem é o chef que descobre a receita?
- 4 – O que é IA?
- 5 – Por que agora?
- 6 – Podemos confiar em ML?
- 7 – Inteligência de Decisão.
- 8 – Aplicada e Básica.
- 9 – Decisão em ML.

1 – O que é
Machine
Learning (ML)?



1 – O que é Machine Learning (ML)?

1943:

Warren McCulloch e Walter Pitts publicam o primeiro modelo matemático de uma Rede Neural


1949:

Donald Hebb publica *The Organization of Behavior: A Neuropsychological Theory*

1950:

Alan Turing publica *Computing Machinery and Intelligence*

The First Neural Network Model 1943



Warren McCulloch and Walter Pitts published a seminal paper in 1943 that proposed a mathematical model of artificial neurons. Their work laid the foundation for neural network research, introducing the concept of threshold logic which later influenced the development of AI.



History and Evolution of Machine Learning: A Timeline

1 – O que é Machine Learning (ML)?

1956:

John McCarthy, Marvin Minsky, Nathaniel Rochester e Claude Shannon cunharam o termo inteligência artificial em uma proposta para um workshop amplamente reconhecido como um evento fundador do campo da AI.



Nathaniel Rochester, Ray Solomonoff, Marvin Minsky, John McCarthy, Claude Shannon e outros cientistas no Projeto de Pesquisa de Verão de Dartmouth sobre Inteligência Artificial, 1956 (Imagem: Margaret Minsky)

1 – O que é Machine Learning (ML)?

1958

Frank Rosenblatt desenvolveu o perceptron, uma rede neural inicial que podia aprender com dados e se tornou a base para redes neurais modernas.

FIG. 1 — Organization of a biological brain. (Red areas indicate active cells, responding to the letter X.)






FIG. 2 — Organization of a perceptron.



1 – O que é Machine Learning (ML)?






1 – O que é Machine Learning (ML)?


É uma abordagem para descobrir qual o conjunto de decisões repetidas (receita, modelo) é capaz de obter padrões em conjuntos de dados usando algoritmos para utilizar essas receitas para descobrir informações em novos dados.

2 – Para quem é Machine Learning?






Para quem **não** é
o Machine
Learning?



Para quem não é o Machine Learning?

- Quando temos todas as observações necessárias;
- Quando temos a receita pronta para o desenvolvimento de um modelo;
- Quando não temos dados suficientes ou esses dados são “problemáticos”;
- Quando os dados não possuem padrão.;



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Para quem não é o Machine Learning?

Quando temos todas as observações necessárias;

1. 50 mg
2. 20 mg
3. 30 mg
4. 10 mg
5. 55 mg
6. 22 mg
7. 33 mg
8. 11 mg
9. 45 mg
10. 18 mg
11. 27 mg
12. 9 mg

1. Qual a 7ª dose?

Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

The final result is $2x$.

Para quem não é o Machine Learning?

Quando temos a receita pronta para o desenvolvimento de um modelo;

1. 50 mg
2. 20 mg
3. 30 mg
4. 10 mg
5. 55 mg
6. 22 mg
7. 33 mg
8. 11 mg
9. 45 mg
10. 18 mg
11. 27 mg
12. 9 mg

Após o 4º dia, incremento 10%
do 1º valor e após o 8º dia,
decremento 10%. Repita.

1. Qual valor da 13ª dose?

R.: 55 mg

$$f(t) = \begin{cases} 0 & \text{se } (t-1) \bmod 8 < 4 \\ 0.1 & \text{se } (t-1) \bmod 8 \geq 4 \end{cases}$$


Handwritten mathematical derivation of the derivative of $f(x) = (x+h)^2 - x^2$ using the limit definition:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Para quem não é o Machine Learning?

Quando não temos dados suficientes ou esses dados são “problemáticos”;

- Dados faltantes (*missing*);
- Poucas observações para a complexidade da pergunta;
- Variáveis fortemente correlacionadas;
- Ausência de correlação com a variável dependente;



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Para quem não é o Machine Learning?

Quando os dados não possuem padrão;




Padrão
artificialmente
criado

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Para quem não é o Machine Learning?

Quando os dados não possuem padrão;



Ausência de
padrão

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$


LABEL



ALL THE THINGS!


memegenerator

Para quem é o
Machine
Learning?



Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;



Padrão linear


$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;

Algoritmos

Neural Network




$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;

Algoritmos

Support Vector Classifier




$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;

Algoritmos

Decision Tree




$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;

Algoritmos

Decision Tree




$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;

Algoritmos

Decision Tree




$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$


Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;

Support Vector Classifier




Decision Tree



$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;



Nova observação?


Variável 1 = 28

Variável 2 = 17

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;



Support Vector Classifier

Nova observação?

R.: O


Variável 1 = 28

Variável 2 = 17

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;



Decision Tree

Nova observação?

R.: X

Variável 1 = 28


Variável 2 = 17

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$


Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;

Support Vector Classifier



Decision Tree




$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;

Qual é o melhor modelo?

Métricas




$$\begin{aligned}f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\&= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\&= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\&= \lim_{h \rightarrow 0} h(2x + h)\end{aligned}$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;

Métricas = 50

Nova Observação



Magenta = 33 = 66%

Azul = 17 = 34%


$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;

Métricas = 50

Decision Tree



Magenta = 8 = 16%

Azul = 40 = 80%

Indet. = 2 = 4%

Erros = 50%


$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;

Métricas = 50

Support Vector Classifier



Magenta = 32 = 64%

Azul = 15 = 30%


Indet. = 3 = 6%

Erros = 2%


$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Machine Learning

Coisas novas;




Support Vector Classifier



Erro = 2%

Decision Tree




Erro = 50%

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Para quem é o Machine Learning?

Quando precisamos ser bem-sucedidos em coisas novas;

É uma abordagem para descobrir qual o conjunto de decisões repetidas (receita, modelo) é capaz de descobrir padrões em conjuntos de dados usando algoritmos e utilizar essas receitas para descobrir informações em novos dados.



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Quem é o chef que descobre a receita?

Dados



Algoritmos



Modelos



Predições



Ingredientes

Chefs

Receitas

Pratos

Quem é o chef que descobre a receita?

Algoritmos = Chefs

Quando eu joga um pouco de orégano
e pimenta do reino no ovo frito



$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Quem é o chef que descobre a receita?

- Regressão Linear;
- k-means;
- k-nn;
- SVM;
- Árvores de Decisão;
- Florestas Aleatórias;
- Naive Bayes;
- Regressão Logística;
- Redes Neurais;



Chef -> Amostra

Quantas colorias temos no Estrogonofe?



Chef -> Amostra

Predizer colorias



Carne	100 cal
Cogumelos	5 cal
Molho inglês	7 cal
Maçã	10 cal
Vinho	150 cal
Trigo	70 cal
Leite	80 cal
Arroz	90 cal
Batata	60 cal

572 cal



Chef -> Médias

Predizer colorias



50 x Estrogonofe

566, 552, 584, 549, 583, 563,
581, 567, 562, 547, 552, 559,
555, 590, 561, 543, 575, 569,
550, 590, 573, 555, 564, 578,
568, 548, 570, 572, 565, 588,
565, 569, 570, 552, 555, 562,
588, 574, 550, 548, 562, 576,
559, 585, 571, 582, 572, 567,
566, 586

Média : 566.76


Mediana : 566.5

Des. Pad.: 12.65




Regressão Linear

Predizer calorias



Regressão Linear

Predizer calorias




$$y = 566 + x * 18 + 0$$



Calorias = Interceptor + Coeficiente Angular * Peso + Variação

Regressão Linear

Predizer calorias




$$y = 100 + x * 18 + 0$$



Calorias = Intercepto + Coeficiente Angular * Peso + Variação

Regressão Linear

Predizer calorias




$$y = 300 + x * 10 + 0$$



Calorias = Interceptor + Coeficiente Angular * Peso + Variação

Regressão Linear

Predizer calorias




$$y = 800 + x \cdot -10 + 0$$



Calorias = Intercepto + Coeficiente Angular * Peso + Variação

Regressão Linear

Predizer calorias




$$y = 566 + x \cdot 0 + 0$$



Calorias = Intercepto + Coeficiente Angular * Peso + Variação

Regressão Linear

Métricas



Root Mean Squared Error

RMSE = ~52k




Calorias = Intercepto + Coeficiente Angular * Peso + Variação

$$y = 566 + x \cdot 0 + 0$$

Regressão Linear

Métricas



Root Mean Squared Error

RMSE = ~24k




Calorias = Interceptor + Coeficiente Angular * Peso + Variação

$$y = 300 + x \cdot 10 + 0$$

Regressão Linear

Métricas



Root Mean Squared Error

RMSE = ~14k



Calorias = Interceptor + Coeficiente Angular * Peso + Variação

$$y = 50 + x * 16 + 0$$

Regressão Linear

Métricas



$$y = 50 + x * 16 + 0 \quad \text{RMSE} = \sim 14k$$

$$y = 300 + x * 10 + 0 \quad \text{RMSE} = \sim 24k$$

$$y = 566 + x * 0 + 0 \quad \text{RMSE} = \sim 52k$$



Calorias = Interceptor + Coeficiente Angular * Peso + Variação

Regressão Linear

Obtendo a melhor receita



Tentativa e erro manualmente

Função de ativação

Calculo




Calorias = Interceptor + Coeficiente Angular * Peso + Variação

Regressão Linear Predizer calorias

Carne
Cogumelos
Molho inglês
Maça
Vinho
Trigo
Leite
Arroz
Batata

Peso -> 18g

572 cal 338 cal



$e = 234$



$$y = 50 + x \cdot 16 + 0$$

$$234 = 50 + 18 \cdot 16 + 0$$

Regressão Multipla Predizer colorias

572 cal



$y = 50$

+ Peso (g) * 16

+ Carne (g) * CA

+ Cogumelos (g) * CA

...

+ 0

643 cal

$e = -71$



Predizer Colorias

Quantas colorias temos no Estrogonofe?

572 cal



Algoritmo (Chef)	Modelo (Receita)	Erro
Média	566	6
Regressão Linear Simples	370	202
Regressão Linear Múltipla	643	-71




Dados


Seu modelo de ML
será tão bom
quanto a qualidade
dos seus dados.




1 – O que é Machine Learning (ML)?




5 – Porque agora?




5 – Porque agora?




5 – Porque agora?




5 – Porque agora?




5 – Porque agora?



Algoritmos mais sofisticados;



Mais Dados;




Mais poder computacional;

5 – Porque agora?

Machine Learning tem sucesso em tarefas muito complicadas as quais programadores não conseguem escrever instruções manualmente

5 – Porque agora?



5 – Porque agora?



Manufacturing

- Predictive maintenance or condition monitoring
- Warranty reserve estimation
- Propensity to buy
- Demand forecasting
- Process optimization
- Telematics



Travel and Hospitality

- Aircraft scheduling
- Dynamic pricing
- Social media – consumer feedback and interaction analysis
- Customer complaint resolution
- Traffic patterns and congestion management



Retail

- Predictive inventory planning
- Recommendation engines
- Upsell and cross-channel marketing
- Market segmentation and targeting
- Customer ROI and lifetime value



Financial Services

- Risk analytics and regulation
- Customer Segmentation
- Cross-selling and up-selling
- Sales and marketing campaign management
- Credit worthiness evaluation



Healthcare and Life Sciences

- Alerts and diagnostics from real-time patient data
- Disease identification and risk stratification
- Patient triage optimization
- Proactive health management
- Healthcare provider sentiment analysis




Energy, Feedstock and Utilities

- Power usage analytics
- Seismic data processing
- Carbon emissions and trading
- Customer-specific pricing
- Smart grid management
- Energy demand and supply optimization

6 – Podemos confiar nela?

Problema da Caixa Preta.

Explicabilidade




6 – Podemos confiar nela?

Métricas

Problema da Caixa Preta.

Explicabilidade



6 – Podemos confiar nela?

Métricas

Teste se funciona e se preocupe
menos em como funciona.



6 – Podemos confiar nela?

Métricas

Treino

Ajuste

Teste

Validação

Uma receita (modelo)
pode apenas decorar as
respostas, e não aprender
os padrões



6 – Podemos confiar nela?

Generalização

Garbage in, garbage out



6 – Podemos confiar nela?

Generalização

Os dados precisam ser relevantes.

Os exemplos, a amostragem, precisa ser relevante.



6 – Podemos confiar nela?

Generalização

Capacidade de ser bom
em **novas informações**



6 – Podemos confiar nela?

Métricas

Overfitting



7 – Inteligência de decisão

Métricas

Erro Tipo I -> Rejeitar erroneamente a hipótese nula

Erro Tipo II -> Não rejeitar erroneamente a hipótese nula

Erro Tipo III -> Rejeitar corretamente a hipótese nula errada (usar a matemática e a estatística para responder a pergunta errada)

7 – Inteligência de decisão

Métricas

Corrigir o erro Tipo III. Aplicar ML, estatística e análise de dados para resolver um problema correto.



8 – Aplicada e Básica

Básica procura melhores algoritmos.

Aplicada usa algoritmos para obter melhores receitas.

8 – Aplicada e Básica

ML é explicar com exemplos e não instruções

ML é automatizar o inefável (inexprimível)

Testes mantem você seguro

Como desenhar o teste? Quem deve desenhar o teste?

Como decidir se o modelo é ou não confiável?

8 – Aplicada e Básica



8 – Aplicada e Básica

Estacionamento com 1.000 vagas, sendo que 10 delas estão livres em média (1%).

Um modelo de ML mostra 95% de
acurácia

Diga que está sempre cheio. Isso
devolve uma média de 99% de
acurácia



9 – Decisão em ML

É sempre necessário que o projeto de ML aplicada tenha uma direção em relação a pergunta biológica.

9 – Decisão em ML

Etapa 0 - 1 - Faça as perguntas certas

Etapa 2 - 4 - Obtenha os dados certos

Etapa 5 - 7 - Use algoritmos para criar receitas a partir de padrões nos dados

Etapa 8 - 9 - Verifique se as receitas funcionam em novos dados

Etapa 10 - Crie um sistema pronto para produção

Etapa 11 - Certifique-se de que o lançamento seja uma boa ideia

Etapa 12 - Mantenha seu sistema de ML de produção confiável ao longo do tempo

Python Machine Learning

The background is a dark, abstract composition. It features numerous thin, glowing green and blue lines that swirl and flow across the frame, creating a sense of dynamic movement. Interspersed among these lines are various letters and symbols in a light green or yellowish hue, some appearing sharp and others blurred, as if they are floating or drifting through space. The overall effect is reminiscent of a digital or data-driven environment.

Target IP:
152.111.193.28
Start Port
2000

Guilherme Silveira
gfsilveira@gmail.com

02/08/2026

9 – Decisão em ML

Etapa 0 - 1 - Defina objetivos de negócios, decida a qualidade necessária

Etapa 2 - 4 - Obtenha, gerencie, prepare os ingredientes certos

Etapa 5 - 7 - Mexa com eletrodomésticos, seja criativo, faça a receita

Etapa 8 - 9 - Prove! Repita se o resultado não for saboroso o suficiente

Etapa 10 - Organize a cozinha para que você possa servir esta receita o dia todo

Etapa 11 - Certifique-se de que os clientes gostem antes de adicioná-la ao menu

Etapa 12 - Mantenha o processo da sua cozinha confiável ao longo do tempo