

Python Machine Learning

Objetivos Machine Learning

Guilherme Silveira
gfsilveira@gmail.com

04/08/2026

3 – Qual é o seu objetivo?





3 – Qual é o seu objetivo?

O sucesso de um modelo de ML depende, antes de tudo, do objetivo que você pretende atingir.

3 – Qual é o seu objetivo?

CAT BODY LANGUAGE



FRIENDLY



RELAXED



INTERESTED



PLAYFUL



YOU ARE MINE



TERRIFIED



TRUSTING



EXCITED



NERVOUS



FRAIGHTENED



IRRITATED



PREDATORY


3 – Qual é o
seu
objetivo?



Depende da pessoa que toma a decisão.

Quando você deve saber o que significa um bom comportamento?

Antes do treinamento.



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f'(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Depende da pessoa que toma a decisão.


Métricas

Erro Tipo I -> Rejeitar erroneamente a hipótese nula

Erro Tipo II -> Não rejeitar erroneamente a hipótese nula

Erro Tipo III -> Rejeitar corretamente a hipótese nula errada


(usar a matemática e a estatística para responder a pergunta errada)



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas



$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Quais os valores que você deseja obter?

Variáveis

Categóricas

Nominal

IL-2, IL-6, IL-10

Ordinal

Malato -> oxalacetato ->
citrato -> isocitrato

1,34g, 1,45mg, 3,56g,
1/2mL

2, 10, 1.254

Numéricas

Contínuas

Discreta

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas

Regressão

Coeficiente de determinação (R^2)
Erro médio absoluto (MAE)
Erro Quadrático Médio (MSE)
Raiz do Erro Quadrático Médio (RMSE)
Erro Percentual Absoluto Médio (MAPE)

Clusterização

Calinski Harabasz
Davies Bouldin
Silhouette
ARI (Adjusted Rand Index)
AMI (Adjusted Mutual Information)

Classificação

Acurácia
Precision
Recall
F1-Score

The image shows a chalkboard with handwritten mathematical derivations. The top part shows the definition of the derivative of a function $f(x)$ as a limit: $f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$. Below this, a specific example is worked out for $f(x) = x^2$. The steps are: $f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$, which expands to $\lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$, simplifies to $\lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$, and finally to $\lim_{h \rightarrow 0} h(2x + h)$.

Regressão

MÉTRICAS DE AVALIAÇÃO DE REGRESSÃO

MAE (Erro Médio Absoluto)

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$



Média das diferenças absolutas.
Intuitivo.

RMSE (Raiz do Erro Quadrático Médio)


$$RMSE = \sqrt{MSE}$$



Raiz quadrada do MSE.
Na unidade original dos dados.

MODELO DE REGRESSÃO

Dados Reais vs. Previsões (y vs $\hat{y}$)



Dados Reais vs. Previsões (y vs $\hat{y}$)


Resumo Comparativo

- Média das diferenças absolutas. Intuitivo.
- Penaliza as diferenças quadradas. Penaliza erros.
- Análise de desempenho do modelo.

Análise de Desempenho do Modelo

MSE (Erro Quadrático Médio)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$



Média das diferenças quadradas.
Penaliza grandes erros.

R² (Coeficiente de Determinação)

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

Variabilidade Explicada
pelo Modelo



Variabilidade Total



ALTO BAIXO

Proporção da variância explicada
pelo modelo (0 a 1).


$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Coeficiente de determinação (R^2)

Regressão

Quão bem um modelo de regressão se ajusta a um conjunto de dados, indicando a proporção da variabilidade na variável dependente que é explicada pelo(s) modelo(s).

Ele varia de 0 a 1 (ou de 0% a 100%)



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Coeficiente de determinação (R^2)

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$


$$R^2 = 1 - \frac{\text{SQR}}{\text{SQT}}$$

$$R^2 = 1 - \frac{0,7}{2,6} \quad R^2 = 0,73$$

Regressão


Soma dos Quadrados Total - SQT

SQT: 2,630,292.04



Soma dos Quadrados Resíduos - SQR

SQR: 722,096.82




$$y = 50 + x \cdot 16 + 0$$

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Erro médio absoluto (MAE)

Regressão

Ela mede a média da diferença absoluta entre os valores previstos pelo modelo e os valores observados.



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:


$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Erro médio absoluto (MAE)

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i|$$

Regressão

$$MAE = \frac{|y_1 \text{ obs} - y_1 \text{ prd}| + |y_2 \text{ obs} - y_2 \text{ prd}| + |y_n \text{ obs} - y_n \text{ prd}|}{n}$$




MAE = 88.11

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Erro Quadrático Médio (MSE)

Regressão

É comumente usado para verificar a acurácia de modelos e dá um maior peso aos maiores erros, já que, ao ser calculado, cada erro é elevado ao quadrado individualmente e, após isso, a média desses erros quadráticos é calculada.



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:


$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Erro Quadrático Médio (MSE)

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Regressão

$$\text{MSE} = \frac{(y_1 \text{ obs} - y_1 \text{ prd})^2 + (y_2 \text{ obs} - y_2 \text{ prd})^2 + \dots + (y_n \text{ obs} - y_n \text{ prd})^2}{n}$$




$$\text{MSE} = 11271.02$$

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Raiz do Erro Quadrático Médio (RMSE)

Regressão

É apenas a raiz quadrada do MSE, onde o erro retorna à unidade de medida do modelo (no MSE, a unidade de medida é quadrática).



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:


$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Raiz do Erro Quadrático Médio (RMSE)

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

Regressão

$$RMSE = \sqrt{\frac{(y_1 \text{ obs} - y_1 \text{ prd})^2 + (y_2 \text{ obs} - y_2 \text{ prd})^2 + \dots + (y_n \text{ obs} - y_n \text{ prd})^2}{n}}$$




RMSE = 106.17

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Erro Percentual Absoluto Médio (MAPE)

Regressão

Esta é outra métrica interessante para usar em relatórios de gerenciamento, porque o erro é medido como uma porcentagem e assim, é possível fazer comparações entre erros percentuais do modelo entre produtos.



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:


$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Erro Percentual Absoluto Médio (MAPE)


$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i} \cdot 100\%$$

Regressão

$$MAPE = \frac{\frac{|y_1 \text{ obs} - y_1 \text{ prd}|}{y_1 \text{ obs}} + \frac{|y_2 \text{ obs} - y_2 \text{ prd}|}{y_2 \text{ obs}} + \frac{|y_n \text{ obs} - y_n \text{ prd}|}{y_n \text{ obs}}}{n} \cdot 100\%$$



MAPE = 0.21



Métrica	Quando Utilizar	Limitações	Considerações Adicionais
Coeficiente de Determinação (R^2)	- Modelos lineares para avaliar o grau de ajuste. - Comparar diferentes modelos.	- Pode dar resultados enganadores em presença de outliers. - Não lida bem com relações não-lineares.	Útil como métrica inicial, mas não indica o erro absoluto ou a escala do erro.
Erro Médio Absoluto (MAE)	- Contextos onde é necessária uma medida intuitiva do erro médio. - Quando se quer evitar penalizar grandes erros.	- Não captura o impacto dos grandes desvios. - Insensível à magnitude do erro.	Simples de interpretar, ideal para conjuntos de dados com poucas flutuações bruscas.
Raiz do Erro Quadrático Médio (RMSE)	- Quando se deseja dar maior peso a grandes erros. - Modelos com distribuição normal dos erros.	- Penaliza severamente grandes desvios. - Não é robusto contra outliers.	Usado em contextos onde grandes desvios são indesejáveis, como em previsões financeiras.
Erro Médio Percentual Absoluto (MAPE)	- Modelos onde a interpretação do erro percentual é mais útil. - Comparação entre diferentes escalas de séries temporais.	- Se valores reais forem zero ou próximos de zero, a métrica se torna instável.	Ideal para comparações entre séries temporais com diferentes magnitudes.

Métricas - Regressão

$$R^2 = 0,73$$

$$MAE = 88.11$$

$$MSE = 11271.02$$

$$RMSE = 106.17$$

$$MAPE = 0.21$$


Classificação

MÉTRICAS DE CLASSIFICAÇÃO

PRECISION PRECISÃO

$$Precision = \frac{TP}{TP + FP}$$

Positive predictions



Dos que o modelo previu como positivos, quantos eram realmente corretos?

F1-SCORE

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$



Média harmônica entre Precisão e Recall. Útil para dados desbalanceados.

CONFUSION MATRIX Matriz de Confusão

VALOR PREVISTO

VALOR REAL	VALOR PREVISTO	
	Positivo	Negativo
Positivo	TRUE POSITIVE (TP) Modelo prevê positivo, é positivo.	FALSE POSITIVE (FP) Modelo prevê positivo, mas é negativo. (Erro Tipo I).
Negativo	FALSE NEGATIVE (FN) Modelo prevê negativo, mas é positivo. (Erro Tipo II).	TRUE NEGATIVE (TN) Modelo prevê negativo, é negativo.
	Positivo	Negativo

VALOR REAL

ROC CURVE & AUC



RECALL / SENSITIVITY RECALL / SENSIBILIDADE

$$Recall = \frac{TP}{TP + FN}$$

Real positives

Real



Positive positives



De todos os positivos reais, quantos o modelo conseguiu identificar?

ACCURACY ACURÁCIA

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Entire sample



Proporção total de previsões corretas (Positivas e Negativas).

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$


$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$

$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$

$$= \lim_{h \rightarrow 0} h(2x + h)$$

Métricas – Matriz de Confusão


Classificação



$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Métricas – Matriz de Confusão

Classificação




- **Acurácia:** $\frac{VP+VN}{VP+VN+FP+FN}$
- **Precisão:** $\frac{VP}{VP+FP}$
- **Recall (Sensibilidade):** $\frac{VP}{VP+FN}$
- **F1-Score:** $2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Quem são os gatos?

Classificação



Quem são os gatos?

Aplicando o modelo

Classificação




Quem são os gatos?

Aplicando o modelo
Verificando

Classificação

FN




TN



TP



FP



Quem são os gatos?

Classificação

TP



FN




FP



TN



Primeiro classifica com o modelo,
depois verifica se está correto



Quem são os gatos?


TP	FN
FP	TN

Observ.

4	2
2	3

Predito

Classificação



Quem são os gatos?

Classificação

TP



FN



FP



TN



TP	FN
FP	TN

Valor Predito		Positivo	Negativo
Valor Real	Positivo	4	2
	Negativo	2	3

Quem são os gatos?

Classificação

TP	FN
FP	TN

- Acurácia: $\frac{VP+VN}{VP+VN+FP+FN}$
- Precisão: $\frac{VP}{VP+FP}$
- Recall (Sensibilidade): $\frac{VP}{VP+FN}$
- F1-Score: $2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$

		Valor Predito	
		Positivo	Negativo
Valor Real	Positivo	4	2
	Negativo	2	3

Quem são os gatos?

Classificação

TP	FN
FP	TN

$$\frac{4 + 3}{4 + 3 + 2 + 2} = 7/11 = 63\%$$

- Acurácia: $\frac{VP+VN}{VP+VN+FP+FN}$

$$\frac{4}{4 + 2} = 4/6 = 66\%$$

- Precisão: $\frac{VP}{VP+FP}$

$$\frac{4}{4 + 2} = 4/2 = 66\%$$

- Recall (Sensibilidade): $\frac{VP}{VP+FN}$

- F1-Score: $2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$

$$2 \times \frac{0,66 \times 0,66}{0,66 + 0,66} = 0,44/1,32 = 33\%$$

		Valor Predito	
		Positivo	Negativo
Valor Real	Positivo	4	2
	Negativo	2	3

Quem são os gatos?

Classificação

TP	FN
FP	TN

Acurácia: 63%

Precisão: 66%

Recall: 66%

F1-score: 33%

		Valor Predito	
		Positivo	Negativo
Valor Real	Positivo	4	2
	Negativo	2	3

Métrica	Descrição	Interpretação
Acurácia	É a quantidade de acertos do nosso modelo dividido pelo total da amostra.	Qual a proporção de gatos e não gatos que foram corretamente classificados.
Precisão	De todos os dados classificados como positivos, quantos são realmente positivos.	Qual a proporção dos dados classificados como gatos eram realmente gatos. (aqui buscamos os falsos positivos)
Recall	Qual a porcentagem de dados classificados como positivos comparado com a quantidade real de positivos que existem em nossa amostra.	Entre todas as amostras que realmente eram de gatos, qual a proporção classificada como gatos. (aqui buscamos os falsos negativos)
F1-Score	Essa métrica une precisão e <i>recall</i> afim de trazer um número único que determine a qualidade geral do nosso modelo.	Uma maneira de observar em um único número a precisão e o recall.

Métricas - Classificação

Acurácia: 63%

Precisão: 66%

Recall: 66%

F1-score: 33%


Precisão: Pode deixar de fora resultados positivos, com a certeza nos positivos que retorna

Recall: Pode devolver resultados positivos ruins, mas devolvem todos os positivos


Clusterização

MÉTRICAS DE AVALIAÇÃO DE CLUSTERIZAÇÃO

1. COESÃO E SEPARAÇÃO (SILHOUETTE SCORE)



2. ÍNDICE DAVIES-BOULDIN (DB)



4. ÍNDICE RAND AJUSTADO (ARI) & INFORMAÇÃO MÚTUA AJUSTADA (AMI)



ARI = Partitratotico, AMI = $\frac{\text{informação (ARI)}}{\text{informação (AMI)}}$

3. ÍNDICE CALINSKI-HARABASZ (CH) (VARIANCE RATIO)



$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Métricas – Silhouette score

Clusterização

O Silhueta Score mede o quão semelhante um ponto de dados é ao seu próprio cluster em comparação com outros clusters. Uma pontuação mais alta indica clusters mais bem definidos e bem separados.

Ele varia de -1 a 1.

INTRINSECO

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Silhouette score

Clusterização

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

$a(i)$ (Coesão): É a distância média entre a amostra i e todos os outros pontos do mesmo cluster A .

$$a(i) = \frac{1}{|A| - 1} \sum_{j \in A, j \neq i} d(i, j)$$

$b(i)$ (Separação): É a distância média mais curta entre a amostra i e todos os pontos de qualquer outro cluster C (do qual i não faz parte).

$$b(i) = \min_{C \neq A} \frac{1}{|C|} \sum_{j \in C} d(i, j)$$

Handwritten mathematical derivation on a chalkboard:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Silhouette score

Clusterização


Valor de $s(i)$	Interpretação
Próximo a +1	Excelente ajuste. A amostra está muito próxima dos pontos do seu próprio cluster e muito distante dos clusters vizinhos.
Próximo a 0	Zona de transição. A amostra está no limite de decisão entre dois clusters sobrepostos.
Próximo a -1	Classificação incorreta. A amostra provavelmente foi atribuída ao cluster errado, pois está mais perto do cluster vizinho do que do seu próprio.

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$


Métricas – Silhouette score

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Clusterização



S = 0.34



Métricas – Calinski Harabasz score

Clusterização

O Calinski-Harabasz Score (também conhecido como Variance Ratio Criterion ou Critério da Razão de Variância) serve principalmente para ajudar a encontrar o número ideal de clusters (k) quando não temos as respostas reais (ground-truth) para comparar. Um bom agrupamento deve ter clusters bem separados entre si (distantes) e internamente compactos (pontos muito próximos uns dos outros).

Quanto maior, melhor.

EXTRINSECO

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Calinski Harabasz score

$$CH = \frac{SS_B}{SS_W} \times \frac{n - k}{k - 1}$$

Clusterização

SSB (Between-cluster Sum of Squares): Mede a dispersão **entre** os clusters (a distância geométrica entre os centroides de cada cluster e o centroide global de todos os dados).

Quanto maior, melhor (indica que os grupos estão distantes uns dos outros).

SSW (Within-cluster Sum of Squares): Mede a dispersão **dentro** dos clusters (a soma dos quadrados das distâncias de cada ponto ao centroide do seu próprio grupo). **Quanto menor, melhor** (indica que os grupos são compactos).

n: Número total de amostras (pontos de dados).

k: Número de clusters.


Handwritten mathematical derivation on a chalkboard:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Calinski Harabasz score

$$CH = \frac{SS_B}{SS_W} \times \frac{n - k}{k - 1}$$

Clusterização



CH = 36.65

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Davies Bouldin Score

Clusterização

O Davies-Bouldin Score (DB Score) assim como o Calinski-Harabasz, avalia a separação entre os clusters e a compactação interna, mas faz isso de uma forma ligeiramente diferente: analisando a "similaridade" par a par entre os grupos.

Quanto maior melhor.

EXTRINSECO

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Davies Bouldin Score

$$R_{ij} = \frac{S_i + S_j}{M_{ij}}$$

Clusterização

A soma dos tamanhos dos clusters ($S_i + S_j$) dividido pela distância real entre eles (M_{ij}), o que vai indicar o grau de sobreposição. O Davies-Bouldin final é a média dos maiores valores de R_{ij} encontrados para cada cluster da base de dados.


Handwritten mathematical derivation on a chalkboard:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Davies Bouldin Score

$$R_{ij} = \frac{S_i + S_j}{M_{ij}}$$

Clusterização



DB = 0.26

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$


Métricas – Índice Rand Ajustado

Clusterização

Em vez de olhar para centroides ou distâncias geométricas, o ARI avalia o agrupamento com base em decisões de emparelhamento. Ele analisa todos os pares possíveis de elementos no seu conjunto de dados e faz uma pergunta simples: "Se dois elementos pertencem ao mesmo grupo no mundo real, o algoritmo também os colocou no mesmo cluster? E se pertencem a grupos diferentes, o algoritmo os separou?"

Varia de -1 a 1.

EXTRINSECO



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Índice Rand Ajustado

Clusterização

$$\frac{TP+TN}{TP+TN+FP+FN} \cdot$$

$$ARI = \frac{\text{Índice Rand} - \text{Índice Esperado}}{\text{Índice Máximo} - \text{Índice Esperado}}$$

Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Índice Rand Ajustado

$$ARI = \frac{\text{Índice Rand} - \text{Índice Esperado}}{\text{Índice Máximo} - \text{Índice Esperado}}$$

Clusterização

Como interpretar o resultado?

- **1.0:** Agrupamento perfeito. O resultado do algoritmo é idêntico aos rótulos reais.
- **0.0:** O agrupamento não é melhor do que escolher os clusters jogando uma moeda ou uma peça de dados ao acaso.
- **Valores negativos:** O alinhamento é pior do que o esperado por puro acaso (indica que os dados foram agrupados de forma sistematicamente oposta à realidade).


Handwritten mathematical derivation on a chalkboard:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Índice Rand Ajustado

$$ARI = \frac{\text{Índice Rand} - \text{Índice Esperado}}{\text{Índice Máximo} - \text{Índice Esperado}}$$

Clusterização



ARI = 0.02

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$


Métricas – Informação Mútua Ajustada

Clusterização

A Informação Mútua Ajustada (ou AMI) se baseia em conceitos da Teoria da Informação (especificamente em Entropia e Informação Mútua) para medir quanta informação compartilhamos entre os agrupamentos reais e os preditos.

Varia de -1 a 1.

EXTRINSECO



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Informação Mútua Ajustada

$$AMI = \frac{MI - E[MI]}{\text{média}(H(U), H(V)) - E[MI]}$$

Clusterização

Para entender o AMI, precisamos quebrar o conceito em três passos simples:

1.Entropia (H): Mede o grau de incerteza ou a quantidade de informação em um conjunto de rótulos. Se os dados estão todos em um único cluster, a entropia é zero (sem incerteza). Se estão distribuídos aleatoriamente, a entropia é alta.

2.Informação Mútua (MI): Mede o quanto de informação os dois agrupamentos (o real e o predito) compartilham. Ela responde à pergunta: *"Se eu souber o cluster que o algoritmo atribuiu a um ponto, o quanto isso reduz a minha incerteza sobre a classe real dele?"*

3.O Ajuste pelo Acaso (Ajustada): A Informação Mútua tradicional (MI) tem um viés indesejado: ela tende a aumentar conforme o número de clusters cresce, mesmo que o agrupamento seja feito ao acaso. O **AMI** corrige isso subtraindo o valor esperado pelo acaso ($E[MI]$) e normalizando o resultado

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Informação Mútua Ajustada

$$AMI = \frac{MI - E[MI]}{\text{média}(H(U), H(V)) - E[MI]}$$

Clusterização

Como interpretar o resultado?

- **1.0:** Agrupamento perfeito. O resultado do algoritmo é idêntico aos rótulos reais.
- **0.0:** O agrupamento não é melhor do que escolher os clusters jogando uma moeda ou uma peça de dados ao acaso.
- **Valores negativos:** O alinhamento é pior do que o esperado por puro acaso (indica que os dados foram agrupados de forma sistematicamente oposta à realidade).


Handwritten mathematical derivation on a chalkboard:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Informação Mútua Ajustada

$$AMI = \frac{MI - E[MI]}{\text{média}(H(U), H(V)) - E[MI]}$$

Clusterização



AMI = 0.03

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métrica	Descrição	Interpretação
Calinski Harabasz	Extrínseco	Quanto menor melhor
Davies Bouldin	Extrínseco	Quanto maior melhor
Silhouette	Intrínseco	1 = Agrupamento perfeito 0 = Aleatório -1 = Pior que aleatório
ARI	Extrínseco	1 = Agrupamento perfeito 0 = Aleatório -1 = Pior que aleatório
AMI	Extrínseco	1 = Agrupamento perfeito 0 = Aleatório -1 = Pior que aleatório

Métricas - Clusterização

Calinski Harabasz = 36.65

Davies Bouldin = 0.26

Silhouette = 0.34

ARI (Adjusted Rand Index) = 0.02

AMI (Adjusted Mutual Information) = 0.03

6 – Podemos confiar nela?

Métricas

Overfitting



3 – Qual é o
seu
objetivo?





Vamos
praticar?

LIMC-IA

Python Machine Learning

Objetivos Machine Learning

Guilherme Silveira
gfsilveira@gmail.com

04/08/2026