

Python Machine Learning

Adquirindo os dados Machine Learning

Guilherme Silveira
gfsilveira@gmail.com

04/08/2026

4 – Aquisição dos dados



4 – Aquisição dos dados

Disponibilidade;
Estruturação;
Balanceamento;
 Pandas;
 Numpy;
 DuckDB;
 Smote;

4 – Disponibilidade



Banco de Dados

Um banco de dados é um sistema de armazenamento de informações que permite a coleta, o armazenamento, a recuperação e a manipulação de dados de maneira estruturada e eficiente.



Banco de Dados


- Armazenamento de Dados:
- Recuperação Eficiente:
- Consistência e Integridade:
- Segurança de Dados:
- Suporte à Tomada de Decisões:
- Escalabilidade:
- Integração com Aplicações:
- Backup e Recuperação:
- Compartilhamento de Dados:
- Gerenciamento de Transações:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$



Banco de Dados


- Bancos de Dados Hierárquicos e em Rede (1960s-1970s):
- Banco de Dados Relacional (1970s):
- Bancos de Dados orientado a Objeto (1980s-1990s):
- Expansão da Capacidade e Paralelismo (1990s):
- Bancos de Dados NoSQL (Anos 2000 em diante):
- Bancos de Dados em Memória (2010s):
- Big Data e Processamento em Tempo Real (2010s em diante):
- Bancos de Dados em Nuvem (2010s em diante):
- Blockchain e Bancos de Dados Distribuídos (2010s em diante):



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

Banco de Dados e Tabelas



VS

Exemplo de interface do Excel e uma tabela de exemplo:

Interface do Excel (aba "Página Inicial"):

- Arquivo
- Página Inicial
- Inserir
- Desenhar
- Layout da Página
- Fórmulas
- Dados
- Revisão
- Exibir

Tabela de Exemplo (Exemplo Múltiplas Abas):

Produtos	Jan	Fev	Mar	Total	Média	%
Produto 01	R\$ 453,00	R\$ 435,00	R\$ 273,00	R\$1.161,00	R\$ 387,00	R\$ 0,22
Produto 02	R\$ 331,00	R\$ 238,00	R\$ 207,00	R\$ 776,00	R\$ 258,67	R\$ 0,14
Produto 03	R\$ 497,00	R\$ 416,00	R\$ 490,00	R\$1.403,00	R\$ 467,67	R\$ 0,26
Produto 04	R\$ 469,00	R\$ 329,00	R\$ 256,00	R\$1.054,00	R\$ 351,33	R\$ 0,20
Produto 05	R\$ 412,00	R\$ 223,00	R\$ 367,00	R\$1.002,00	R\$ 334,00	R\$ 0,19


Banco de Dados

- **Banco de Dados:** É usado quando você precisa de um sistema organizado e escalável para armazenar grandes volumes de dados, com estrutura bem definida. É ideal para aplicações complexas, como sistemas biológicos, onde a segurança, a integridade dos dados e as consultas sofisticadas são essenciais.

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Tabelas


- **Tabelas:** É uma opção mais simples e adequada para tarefas pessoais ou pequenos projetos. As planilhas são mais flexíveis, mas podem ser menos eficientes e seguras para grandes volumes de dados. São comumente usadas para cálculos, orçamentos e análises simples.



Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f'(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Sistema de Gerenciamento de Banco de Dados (DBMS)




DBMS mais usados

- MySQL:
- PostgreSQL:
- Oracle Database:
- Microsoft SQL Server:
- MongoDB:
- Redis:
- Cassandra:
- SQLite
- Neo4j:
- Elasticsearch:
- Amazon RDS:
- Google Cloud Spanner:

Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$






O DuckDB é um sistema de gerenciamento de banco de dados relacional, incorporado e de código aberto, explicitamente otimizado para cargas de trabalho analíticas (Processamento Analítico Online – OLAP). Ele é frequentemente descrito como o "SQLite para análise de dados", pois é executado dentro de um processo hospedeiro, sem exigir um servidor de banco de dados dedicado e separado.

SQL - Structured Query Language

O SQL é uma linguagem computacional para trabalhar com conjuntos de fatos e as relações entre eles.

```
SELECT Last_Name
FROM Contacts
WHERE First_Name = 'Mary';
```






DuckDB




```
1 data_file = './data/04_aula_df_gera.csv'
2 df.to_csv(data_file, index=False)
3 db.sql(f"SELECT * FROM read_csv('{data_file}') LIMIT 5")
```

num_cont double	num_disc double	cat_nomi varchar	cat_ordi varchar
1.9934283060224653	3.0	anhaloudine	midi
0.7234713976576307	2.0	joke	maxi
2.295377076201385	1.0	orthobiosis	maxi
4.046059712816051	-1.0	takedown	micro
0.5316932505533281	2.0	becrimson	midi

Bancos de Dados em Python



Ambiente de Desenvolvimento




Docker



O Docker é uma plataforma projetada para ajudar desenvolvedores a criar, compartilhar e executar aplicativos em contêiner.

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Docker




Windows

Linux

Docker

Container



Git + GitHub




Git é um sistema de controle de versão distribuído, gratuito e de código aberto, projetado para lidar com tudo, desde projetos pequenos até muito grandes, com rapidez e eficiência.

O **GitHub** é uma plataforma proprietária para desenvolvedores que permite criar, armazenar, gerenciar e compartilhar seu código online. Ele utiliza o **Git** para fornecer uma versão distribuída.

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Git + GitHub



git init

Inicia uma pasta para controle de versão

git status

verifica a condição de modificação dos arquivos


git add .

adiciona todas as modificações ao sistema de monitoramento

git commit -m "Mensagem"

registra as informações das modificações

Git + GitHub



git branch -M main

modifica o nome da Branch (galho) para main, padrão do GitHub

git remote add origin <url endereço no GitHub>

indica a url do repositório no GitHub e adiciona um alias “origin” para a url

git push -u origin main

envia os commite para branch principal para a url do repositório GitHub

git log

mostra os commite em ordem cronológica

Git + GitHub



`git add .`

`git commit -m "Mensagem"`


`git push -u origin main`

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

4 – Estruturação



Estruturação




`pip install ydata-profiling`

```
1 def gerador_reporte(c: int) -> None:
2     ...
3     Gera um relatório de perfilamento para o dataframe especificado
4     pelo índice c na lista de dataframes.
5     O relatório é salvo como um arquivo HTML.
6     Parametros:
7         c (int): Índice do dataframe na lista de dataframes.
8     Retorna:
9         None
10    ...
11    df = load(lista_df[c])
12    display(lista_df[c])
13    display(df.head())
14    profile = ProfileReport(df, title="Profiling Report")
15    profile.to_file(lista_df[c]+"_report.html")
16
17    return None
```

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Estruturação



Overview

Brought to you by [YData](#)

Overview Alerts 5 [Reproduction](#)

Dataset statistics

Number of variables	5
Number of observations	100
Missing cells	0
Missing cells (%)	0.0%
Duplicate rows	0
Duplicate rows (%)	0.0%
Total size in memory	4.0 KiB
Average record size in memory	41.3 B

Variable types

Numeric	5
---------	---

Variables


Select Columns ▾

a

Real number (R)

Unique

Distinct	100	Minimum	0.014177616
Distinct (%)	100.0%	Maximum	0.99797635
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	0.50348085	Memory size	928.0 B



Estruturação

Dados ausentes

isna() ou isnull()

dropna()

drop_duplicates()

fillna()

bfill()

ffill()

replace()

Transformação de Categorias

get_dummies()

one-hot encoding

Discretização

qcut()

cut()

Handwritten mathematical derivation of the derivative of $f(x) = x^2$ using the limit definition:

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Estruturação


	num_cont	num_disc	cat_nomi	cat_ordi
0	-1.576326	-1.0	eolation	micro
1	4.313191	1.0	tacit	maxi
2	-0.830088	2.0	logo	mini
3	3.887653	NaN	antonomasy	maxi
4	2.087225	4.0	bourg	micro

	num_cont	num_disc	cat_ordi_maxi	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_min	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	1.993428	3	0	0	1	0	0	0	0	1
1	0.723471	2	1	0	0	0	1	0	0	0
2	2.295377	1	1	0	0	0	0	0	1	0
3	4.046060	-1	0	1	0	0	0	1	0	0
4	0.531693	2	0	0	1	0	0	1	0	0




União de tabelas

Merge



União de tabelas

Merge



$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$
$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$
$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$
$$= \lim_{h \rightarrow 0} h(2x + h)$$

União de tabelas

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini
0	anhaloudine	0	1	0
1	joke	0	0	0
2	orthobiosis	0	0	0
3	takedown	1	0	0
4	becrimson	0	1	0

	id	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhaloudine	0	0	1
1	joke	0	0	0
2	orthobiosis	0	1	0
3	takedown	1	0	0
4	becrimson	1	0	0

Left

```
1 df1.merge(df2, on="id", how="left")
✓ 0.0s
```

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhaloudine	0	1	0	0	0	1
1	joke	0	0	0	0	0	0
2	orthobiosis	0	0	0	0	1	0
3	takedown	1	0	0	1	0	0
4	becrimson	0	1	0	1	0	0

Right

```
1 df1.merge(df2, on="id", how="right")
✓ 0.0s
```

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhaloudine	0	1	0	0	0	1
1	joke	0	0	0	0	0	0
2	orthobiosis	0	0	0	0	1	0
3	takedown	1	0	0	1	0	0
4	becrimson	0	1	0	1	0	0

Inner

```
1 df1.merge(df2, on="id", how="inner")
✓ 0.0s
```

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhaloudine	0	1	0	0	0	1
1	joke	0	0	0	0	0	0
2	orthobiosis	0	0	0	0	1	0
3	takedown	1	0	0	1	0	0
4	becrimson	0	1	0	1	0	0

Outer

```
1 df1.merge(df2, on="id", how="outer")
✓ 0.0s
```

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhaloudine	0	1	0	0	0	1
1	joke	0	0	0	0	0	0
2	orthobiosis	0	0	0	0	1	0
3	takedown	1	0	0	1	0	0
4	becrimson	0	1	0	1	0	0

União de tabelas

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini
0	anhalouidine	0	1	0
1	joke	0	0	0
2	orthobiosis	0	0	0
3	takedown	1	0	0
4	becrimson	0	1	0

	id	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhalouidine	0	0	1
1	joke	0	0	0
2	orthobiosis	0	1	0
3	takedown	1	0	0

Left

```
1 df1.merge(df2_sem4, on="id", how="left")
```

✓ 0.0s

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhalouidine	0	1	0	0.0	0.0	1.0
1	joke	0	0	0	0.0	0.0	0.0
2	orthobiosis	0	0	0	0.0	1.0	0.0
3	takedown	1	0	0	1.0	0.0	0.0
4	becrimson	0	1	0	NaN	NaN	NaN

Right

```
1 df1.merge(df2_sem4, on="id", how="right")
```

✓ 0.0s

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhalouidine	0	1	0	0	0	1
1	joke	0	0	0	0	0	0
2	orthobiosis	0	0	0	0	1	0
3	takedown	1	0	0	1	0	0

Inner

```
1 df1.merge(df2_sem4, on="id", how="inner")
```

✓ 0.0s

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhalouidine	0	1	0	0	0	1
1	joke	0	0	0	0	0	0
2	orthobiosis	0	0	0	0	1	0
3	takedown	1	0	0	1	0	0

Outer

```
1 df1.merge(df2_sem4, on="id", how="outer")
```

✓ 0.0s

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhalouidine	0	1	0	0.0	0.0	1.0
1	joke	0	0	0	0.0	0.0	0.0
2	orthobiosis	0	0	0	0.0	1.0	0.0
3	takedown	1	0	0	1.0	0.0	0.0
4	becrimson	0	1	0	NaN	NaN	NaN

União de tabelas

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini
0	anhaloudine	0	1	0
1	joke	0	0	0
2	orthobiosis	0	0	0
4	becrimson	0	1	0

	id	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhaloudine	0	0	1
1	joke	0	0	0
2	orthobiosis	0	1	0
3	takedown	1	0	0

Left

```
1 df1_sem3.merge(df2_sem4, on="id", how="left")
```

✓ 0.0s

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhaloudine	0	1	0	0.0	0.0	1.0
1	joke	0	0	0	0.0	0.0	0.0
2	orthobiosis	0	0	0	0.0	1.0	0.0
3	becrimson	0	1	0	NaN	NaN	NaN

Right

```
1 df1_sem3.merge(df2_sem4, on="id", how="right")
```

✓ 0.0s

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhaloudine	0.0	1.0	0.0	0	0	1
1	joke	0.0	0.0	0.0	0	0	0
2	orthobiosis	0.0	0.0	0.0	0	1	0
3	takedown	NaN	NaN	NaN	1	0	0

Inner

```
1 df1_sem3.merge(df2_sem4, on="id", how="inner")
```

✓ 0.0s

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhaloudine	0	1	0	0	0	1
1	joke	0	0	0	0	0	0
2	orthobiosis	0	0	0	0	1	0

Outer

```
1 df1_sem3.merge(df2_sem4, on="id", how="outer")
```

✓ 0.0s

	id	cat_ordi_micro	cat_ordi_midi	cat_ordi_mini	cat_nomi_len_qcut_25%	cat_nomi_len_qcut_50%	cat_nomi_len_qcut_75%
0	anhaloudine	0.0	1.0	0.0	0.0	0.0	1.0
1	joke	0.0	0.0	0.0	0.0	0.0	0.0
2	orthobiosis	0.0	0.0	0.0	0.0	1.0	0.0
3	becrimson	0.0	1.0	0.0	NaN	NaN	NaN
4	takedown	NaN	NaN	NaN	1.0	0.0	0.0

União de tabelas

Concat

```
1 pd.concat([df1, df2], axis='rows')
```

✓ 0.0s

	num_cont	num_disc	cat_ordi_maxi	cat_ordi_micro
0	1.993428	3	0	0
1	0.723471	2	1	0
2	2.295377	1	1	0
3	4.046060	-1	0	1
4	0.531693	2	0	0
0	0.437799	3	0	1
1	4.595373	1	0	0
2	2.281686	-1	0	0
3	-0.142358	1	1	0
4	2.145166	-1	0	0

	num_cont	num_disc	cat_ordi_maxi	cat_ordi_micro
0	1.993428	3	0	0
1	0.723471	2	1	0
2	2.295377	1	1	0
3	4.046060	-1	0	1
4	0.531693	2	0	0
	num_cont	num_disc	cat_ordi_maxi	cat_ordi_micro
0	0.437799	3	0	1
1	4.595373	1	0	0
2	2.281686	-1	0	0
3	-0.142358	1	1	0
4	2.145166	-1	0	0

União de tabelas

Concat

	num_cont	num_disc	cat_ordi_maxi	cat_ordi_micro
0	1.993428	3	0	0
1	0.723471	2	1	0
2	2.295377	1	1	0
3	4.046060	-1	0	1
4	0.531693	2	0	0

	num_cont	num_disc	cat_ordi_maxi	cat_ordi_micro
0	0.437799	3	0	1
1	4.595373	1	0	0
2	2.281686	-1	0	0
3	-0.142358	1	1	0
4	2.145166	-1	0	0


```
1 pd.concat([df1, df2], axis='columns')
```

✓ 0.0s

	num_cont	num_disc	cat_ordi_maxi	cat_ordi_micro	num_cont	num_disc	cat_ordi_maxi	cat_ordi_micro
0	1.993428	3	0	0	0.437799	3	0	1
1	0.723471	2	1	0	4.595373	1	0	0
2	2.295377	1	1	0	2.281686	-1	0	0
3	4.046060	-1	0	1	-0.142358	1	1	0
4	0.531693	2	0	0	2.145166	-1	0	0



Balanceamento



Balanceamento

```
1 unique_elements, counts = np.unique(y_train, return_counts=True)
2 print(np.asarray((unique_elements, counts)).T)
```

```
[[ 0 630]
 [ 1 70]]
```

```
1 unique_elements, counts = np.unique(y_res, return_counts=True)
2 print(np.asarray((unique_elements, counts)).T)
```

```
[[ 0 630]
 [ 1 630]]
```

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$



Vamos
praticar?

LIMC-IA

Python Machine Learning

Adquirindo os dados Machine Learning

Guilherme Silveira
gfsilveira@gmail.com

04/08/2026