

Python Machine Learning

Treinamento

Guilherme Silveira
gfsilveira@gmail.com

31/07/2026

9 – Treinamentos



Quem é o chef que descobre a receita?

Dados



Algoritmos



Modelos



Predições




Ingredientes

Chefs

Receitas

Pratos

Qual o seu maior pesadelo?



Dados

Dados



Ruim



Bom



Bom



Melhor

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Quantas variáveis devemos usar?



- Não é necessário utilizar todas as variáveis obtidas;
- A menor correlação entre as variáveis é mais indicado;
- “Maldição da Dimensionalidade”;
- Não é porque você tem “ingredientes” é que você deve usar;

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Quantas variáveis devemos usar?

Dados



Como saber?


- Tentativa e erro.

e ...



$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas



$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Validação Cruzada

Dados



Amostragem do Banco

- Cross Validation Score
- K-fold
- Stratified K-Fold



$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Transformações

Dados



Edição das Variáveis

- Standard Scaler
- One Hot Encoder



$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

10 – Tuning



Tuning?



Seleção de variáveis

- Feature Selection



$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

11 – Debug



Debugging?



Ajuste de hiperparâmetros


- Grid Search



$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Qual o seu maior pesadelo?

SELEÇÃO DE VARIÁVEIS e
OTIMIZAÇÃO DE HIPERPARÂMETROS




Treinamento - 70%

Métricas

Validação - 20%



Algoritmos




Teste - 10%

Modelos



Estatística



Qual o seu maior pesadelo? *Overfitting*

Métricas



$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Cadeia de Processos



Organizando

- Pipeline

1. Pré-processamento
2. Treinamento
 - I. Seleção de Variáveis – Tuning
 - II. Seleção de Hiperparâmetros e Validação cruzada
 - Debug e Cross Validation
3. Métricas de Validação
4. Testagem

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Pré-processamento

Dados



Nome da Função/Classe	Biblioteca	Resumo da Função no Script Regression.regress
StandardScaler	sklearn.preprocessing	Padroniza as características numéricas subtraindo a média e dividindo pelo desvio padrão.
OneHotEncoder	sklearn.preprocessing	Codifica características categóricas em um vetor one-hot, removendo a primeira categoria e tratando valores desconhecidos.
FunctionTransformer	sklearn.preprocessing	Cria um transformador que aplica uma função genérica (no script, usado para converter dados para tensor para a rede neural, mas generalizado para processamento genérico na imagem para foco em sklearn).

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Pré-processamento

Dados



Nome da Função/Classe	Biblioteca	Resumo da Função no Script Regression.regress
ColumnTransformer	sklearn.compose	Aplica diferentes pré-processadores (StandardScaler, OneHotEncoder) a colunas específicas baseadas em seus tipos de dados (numérico/categórico).
Pipeline	sklearn.pipeline	Organiza sequencialmente as etapas do fluxo de trabalho (pré-processamento, seleção de variáveis, estimador) como um único objeto.
VarianceThreshold	sklearn.feature_selection	Seleciona características removendo aquelas com variância abaixo de um limiar especificado (threshold=1e-4 no script).

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Seleção de Variáveis – Tuning



Nome da Função/Classe	Biblioteca	Resumo da Função no Script Regression.regress
SelectKBest	sklearn.feature_selection	Seleciona as k melhores características baseadas em um teste estatístico de correlação (f_regression).
f_regression	sklearn.feature_selection	Função de pontuação baseada em teste F, usada pelo SelectKBest para avaliar a relação linear entre características e o alvo.

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Seleção de Hiperparâmetros e Validação cruzada – Debug e Cross Validation



Nome da Função/Classe	Biblioteca	Resumo da Função no Script Regression.regress
GridSearchCV	sklearn.model_selection	Realiza busca exaustiva pelos melhores hiperparâmetros de um estimador usando validação cruzada.
RandomizedSearchCV	sklearn.model_selection	Realiza busca aleatória pelos melhores hiperparâmetros (usada para o modelo de rede neural, que está fora do escopo da imagem, mas incluída na tabela como usada no script para model_selection).
Kfold	sklearn.model_selection	Divide o conjunto de dados em k folds aleatórios para a validação cruzada usada nos métodos de busca.

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

$$f(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h}$$

$$= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h}$$

$$= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h}$$

$$= \lim_{h \rightarrow 0} h(2x + h)$$

Treinamento



Nome da Função/Classe	Biblioteca	Resumo da Função no Script Regression.regress
LinearRegression	sklearn.linear_model	Implementa o modelo de regressão linear simples.
BayesianRidge	sklearn.linear_model	Implementa o modelo de regressão linear bayesiana.
SVR	sklearn.svm	Implementa o modelo de Regressor de Vetores de Suporte com kernel configurável (linear/rbf no script).

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas – Validação



Nome da Função/Classe	Biblioteca	Resumo da Função no Script Regression.regress
mean_squared_error	sklearn.metrics	Calcula o erro quadrático médio (MSE) entre valores observados e preditos.
r2_score	sklearn.metrics	Calcula o coeficiente de determinação (R^2) da regressão.
mean_absolute_error	sklearn.metrics	Calcula o erro absoluto médio (MAE).

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Métricas




Nome da Função/Classe	Biblioteca	Resumo da Função no Script Regression.regress
mean_absolute_percentage_error	sklearn.metrics	Calcula o erro percentual absoluto médio (MAPE).
Spearmanr	scipy.stats	Calcula o coeficiente de correlação de postos de Spearman e o p-value.

$$\begin{aligned} f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\ f(x) &= \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{x^2 + 2xh + h^2 - x^2}{h} \\ &= \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} \\ &= \lim_{h \rightarrow 0} h(2x + h) \end{aligned}$$

Clusterização

Nome do Teste / Métrica	Descrição	Casos de Uso
chi2_stat (Estatística Qui-quadrado)	É o valor numérico resultante de um teste Qui-quadrado. Ele quantifica a magnitude da diferença entre as frequências que foram observadas nos dados e as frequências que seriam esperadas se não houvesse relação entre as variáveis.	Seleção de atributos (feature selection) em aprendizado de máquina para ranquear a importância de variáveis categóricas em relação a uma variável alvo; testes de aderência (goodness-of-fit).
ari_score (Adjusted Rand Index)	Não é exatamente um teste de hipótese, mas uma métrica de similaridade. O ARI mede a similaridade entre duas atribuições de agrupamentos (clusters), ajustando a chance de agrupamentos aleatórios. Varia de -1 a 1, onde 1 indica agrupamentos idênticos.	Avaliação de desempenho de algoritmos de clusterização (não supervisionados) comparando os clusters criados pelo modelo com os rótulos reais conhecidos (ground truth).

Estatística




Teste – 10%

Modelos



Classificação

Nome do Teste / Métrica	Descrição	Casos de Uso
chi2_contingency (Teste Qui-quadrado de Independência)	Teste de hipótese estatística utilizado para determinar se existe uma associação significativa entre duas variáveis categóricas (qualitativas), analisando uma tabela de contingência.	Verificar se duas características estão associadas. Exemplo: analisar se a ocorrência de uma complicação médica (sim/não) é independente do grupo de tratamento (droga A/droga B).



Teste – 10%


Modelos



Regressão

Nome do Teste / Métrica	Descrição	Casos de Uso
ks_2samp (Teste Kolmogorov-Smirnov de 2 Amostras)	Teste não paramétrico que compara as distribuições cumulativas de duas amostras independentes para avaliar a probabilidade de ambas terem sido extraídas da mesma população contínua.	Detectar data drift (desvio de dados) comparando a distribuição de dados de treino com dados de produção; verificar se duas amostras possuem a mesma forma de distribuição.
ttest_ind (Teste t de Student Independente)	Teste paramétrico que avalia se existe uma diferença estatisticamente significativa entre as médias de dois grupos independentes. Assume que os dados seguem uma distribuição normal.	Comparar a média de uma variável contínua entre dois grupos distintos. Exemplo: comparar a pressão arterial média entre pacientes que receberam o tratamento e pacientes do grupo controle.
mannwhitneyu (Teste U de Mann-Whitney)	Teste não paramétrico que serve como alternativa ao teste t independente. Ele não assume que os dados seguem uma distribuição normal e trabalha com o ranqueamento (ordem) das observações em vez dos valores absolutos.	Comparar dois grupos independentes quando os dados contínuos violam a suposição de normalidade (são muito assimétricos) ou quando a variável dependente é ordinal.
levne (Teste de Levene)	Teste inferencial usado para verificar se dois ou mais grupos possuem variâncias iguais (homocedasticidade). Uma variância significativamente diferente entre os grupos resulta na rejeição da hipótese nula do teste.	Validar pressupostos estatísticos antes de aplicar testes paramétricos que exigem variâncias iguais, como a ANOVA (Análise de Variância) ou o próprio teste t clássico.

Estatística



Teste – 10%

Modelos



Responsabilidades e Fluxo: Scikit-Learn e SciPy no Script 'Regression.regress'

Regressor genérico que encapsula diferentes modelos de aprendizado de máquina.

Início do Script

Classe 'Regression': 'regress(modelo)' (Orquestração de Fluxo)

Scikit-Learn (sklearn)

Fase de Pré-processamento de Dados (Compose & Preprocessing)

StandardScaler 🐼 Padronização Numérica
OneHotEncoder 🐼 Codificação Categórica
FunctionTransformer Converteram te datai
ColumnTransformer
Aplicação de Pré-processadores por Coluna

Pipeline

Organização do Fluxo de Trabalho
(Pré-processamento, Seleção, Estimador)

Fase de Seleção de Características (Feature Selection)

VarianceThreshold 🐼
Remoção de Baixa Variância

SelectKBest
f_regression
Seleção das Top k Variáveis baseada
em Teste Estatístico

Fase de Modelagem (Linear Model & SVM)

LinearRegression 🐼
Regressão Linear Simples

BayesianRidge 🐼
Regressão Linear Bayesiana

SVR
Regressor de Vetores de
Suporte

Fase de Otimização e Validação (Model Selection)

GridSearchCV // RandomizedSearchCV
Busca Exaustiva / Aleatória de Hiperparâmetros

KFold 🐼
Validação Cruzada (K Folds)

Predição de Resultados

Métricas de Desempenho do Scikit-Learn (Metrics)

mean_squared_error
Erro Quadrático Médio

r2_score
Coeficiente de Razão R²

mean_absolute_percentage_error
Erro Percentual Absoluto Médio


Métricas de Correlação do SciPy (Stats)

spearmanr
Coeficiente de Correlação de Spearman


Saída de Resultados (Tabela e Previsões)

Resumo:
Geração de Tabela de Métricas a Arrays de Previsões.


Fluxo de Processamento de Informações da Função 'Regression.regress'



Fluxo de Processamento de Informações do Método 'Classifier.classify'



Fluxo de Processamento de Informações da Função "Clustering.cross_validation"





Vamos
praticar?

LIMC-IA

Python Machine Learning

Treinamento

Guilherme Silveira
gfsilveira@gmail.com

31/07/2026