

Curitiba, 16/06/2026

1) Nome Disciplina:

Python Machine Learning – v01/26

2) Coordenador:

Guilherme Ferreira Silveira.

3) Professores:

Guilherme Ferreira Silveira.

4) Carga horária:

60h/atividade presencial.

4 créditos.

5) Mestrado e Doutorado:


Mestrado e Doutorado

6) Pré-requisitos:

Python Machine Learning

7) Ementa:

A disciplina tem como objetivo instrumentalizar os alunos em conceitos intermediários e avançados da linguagem de programação Python, em um contexto de projetos baseados em perguntas que utilizam Machine Learning (ML). Para tanto, serão abordados os conhecimentos iniciais, determinando em quais perguntas são aplicadas técnicas de ML e em quais objetivos podem ser desenvolvidos com essas técnicas. O próximo passo é quanto a aquisição dos bancos de dados, disponibilidade de informações, estruturação e balanceamento. Seguimos com a divisão da base de dados em treinamento, ajustes, validação e testes, etapa crucial para todo projeto de




ML. Uma vez obtidos os bancos, serão realizadas estruturação, análises exploratórias e seleção das variáveis mais relevantes ao modelo. Com o banco pronto, passamos a seleção de algoritmos, baseados em diferentes abordagens e da pergunta a ser explorada. Com essas etapas finalizadas, passamos ao treinamento dos algoritmos selecionados, ajustes e correções dos hiperparâmetros dos modelos e validação, usando as métricas determinadas pelas perguntas iniciais. Finalmente, realizaremos testes estatísticos para determinar a qualidade de nossos modelos. Uma vez obtido o modelo, passamos a etapa de disponibilização e monitoramento desses modelos em sistemas online, com o intuito de explorar a capacidade escalável do Python.

Na trajetória pela disciplina será utilizado e estudado conceitos matemáticos e estatísticos, bem como de programação de softwares e bibliotecas específicas do Python, como:

- *Pandas;*
- *Numpy;*
- *SQLite;*
- *Scikit-learning*
- *Statsmodels;*
- *Tensorflow;*
- *Keras;*
- *GridSearchCV*
- *PyTest*
- *Pipeline e Agregat*
- *Streamlit*
- *Matplotlib*
- *Seaborn*
- *Smote (Oversampling)*

8) Bibliografia:

1. An Introduction to Statistical Learning – Gareth James (Author).
2. Python Data Science Handbook: Essential Tools for Working with Data – Jake VanderPlas (Author).
3. Statistics for Life Sciences – Myra L. Samuels (Author).



4. Python's documentation. <https://www.python.org/doc/>
5. PEP 8 -- Style Guide for Python Code. <https://www.python.org/dev/peps/pep-0008/>
6. Make code slow and complex. Silveira. <https://medium.com/@gfsilveira/make-code-slow-and-complex-222c3c2cd316>

9) Natureza:

Teórica e prática

10) Observações:

É necessário, como pré-requisito para a disciplina, que o aluno tenha sido aprovado em Python Básico (modelo EAD) ou Python Básico Presencial.

11) Período:

De 03/08 a 29/10.

Serão 16 aulas, segundas-feiras das 08h às 12h. E terças-feiras das 13h às 17h.

1 – O que é Machine Learning?


2 – Machine Learning é para mim?

3 – Objetivos:

- Determine o que é sucesso na obtenção de um modelo;
- Metas com base nos objetivos específicos;

4 – Aquisição dos dados:

- Disponibilidade;
- Estruturação;
- Balanceamento;
 - *Pandas*;
 - *Numpy*;
 - *SQLite*;
 - *Smote*;



5 – Algoritmos:

- k-Means;
- k-NN;
- Logistic Regression;
- SVM;
- Decision Trees;
- Random Forests;
- Naive Bayes;
- Simple/Multiple Linear Regression;
- Neural Networks

6 – Divisão da base de dados:

- Treino;
- Ajuste;
- Validação;
- Teste;
 - *Scikit-learning*

7 – Estruturação, Análise Exploratória de Dados e Seleção de Variáveis:

- Tabela e Frequência e Medidas Resumo;
- Correlação;
- Redução de Dimensionalidade;
 - *Statsmodels*;

8 – Seleção de Algoritmos:


- Classificação;
- Regressão;
- Clusterização;
- Redes Neurais;
 - *Tensorflow*;
 - *Keras*;

9 – Treinamento:

- Normalização e padronização;
- Prática de treinamento dos algoritmos;

10 – Ajuste e Debug:

- Ajuste de hiperparâmetros;



- Correção de erros do modelo treinado (tamanho do banco, seleção de variáveis etc.);
 - *GridSearchCV*

11 – Validação:

- Matrix de Confusão;
- Métricas de Erro Padrão;

12 – Teste:

- Teste de hipótese entre predito e observado;

13 – Produção (back end):

- Programação Orientada a Objetos;
- Testes automatizados;
- CI/CD;
 - *PyTest*
 - *Pipeline e Agregat*

14 – Experimento da vida real (front end):

- Teste seu modelo em nova amostragem;
 - *Streamlit*

15 – Monitoramento e manutenção:

- Quando um modelo deve ser substituído;

12) Número máximo de alunos:

12 alunos.

13) Aceita alunos externos:

Sim

Guilherme Ferreira Silveira
Pesquisado em Saúde Pública
Mat. SIAPE: 2175165
Instituto Carlos Chagas – ICC
FIOCRUZ-PR